

Universidade de Coimbra  
Faculdade de Ciências e Tecnologia  
Departamento de Engenharia Informática

Introdução à Inteligência Artificial  
2017/2018 - 2º Semestre



## Trabalho Prático Nº2

***Brain Finder:  
How I Learned to Stop Worrying and Love AI***

Diogo Moreira Albuquerque nº2015248499 [diogoma@student.dei.uc.pt](mailto:diogoma@student.dei.uc.pt) PL2  
José Miguel Saraiva Monteiro nº 2015235572 [jmonteiro@student.dei.uc.pt](mailto:jmonteiro@student.dei.uc.pt) PL5  
Renato José Miranda dos Santos nº2015237457 [renatojms@student.dei.uc.pt](mailto:renatojms@student.dei.uc.pt) PL6

### INTRODUÇÃO

O Objetivo deste trabalho prático consiste na implementação de algoritmos de pesquisa cega, heurística e estocástica, de modo a ajudarem a múmia, Marvin, a encontrar o seu cérebro perdido.

Num ambiente poderão existir vários cérebros, que deverão ser visitados pela mesma ordem. O Marvin ao utilizar um algoritmo de procura descobre a maneira de se deslocar até ao primeiro cérebro. Após esse primeiro objetivo, recupera a sua energia e depois recomeça a sua procura pelo cérebro seguinte, processo este que é repetido até o Marvin visitar todos os cérebros ou ficar sem energia ou força.

## MODELAÇÃO

Neste trabalho, o problema exposto trata-se de um problema de procura, pois o Marvin precisa de descobrir qual o caminho até ao seu cérebro.

O que é um estado?

Um estado é o que define um problema pelo conjunto possível das suas configurações, representando assim cada uma das possibilidades

Qual o estado inicial?

O estado inicial é o estado em que ainda não houve qualquer movimentação por parte do agente.

Como se define um estado final?

O estado final é aquele que satisfaz o objetivo estipulado no enunciado do problema. Para o nosso trabalho, o estado final é quando a múmia encontra o cérebro final.

Quais são os operadores de mudança de estado?

A mudança de estado ocorre sempre que a múmia se desloca, apanhando ou não um cérebro.

Qual a natureza da solução pretendida?

No caso dos algoritmos de procura cega, não existe nenhuma informação sobre o problema para ajudar a encontrar o melhor caminho, então definimos um modo sistemático de navegar na árvore de procura, até que chegue ao estado final, podendo ser analisado de duas maneiras: analisar repetidamente um sucessor do último nó analisado; ou analisar todos os sucessores de um dado nó, antes de passar para a análise de todos os sucessores dos sucessores.

Nos algoritmos de procura heurística, admitimos que possuímos informação adicional que nos torna capaz de estimar o custo do caminho do nó corrente até ao nó solução, dado pela função  $h(n)$ . Pretendendo-se assim que a solução seja melhor, no caso da procura sôfrega, e que a melhor solução seja encontrada pelo  $A^*$ , que tenta escolher a cada instante o melhor caminho passando pelo nó  $n$ , utilizando a função  $f(n) = g(n) + h(n)$ .

Nos algoritmos de procura estocástica, se utilizarmos a procura aleatória irá escolher de forma aleatória qual o próximo nó a ser analisado e expandido. Se utilizarmos a recristalização simulada, procuramos evitar cair em máximos locais, em que em cada momento é selecionado aleatoriamente um sucessor do nó corrente, cujo valor heurístico se for melhor do que o nó corrente, é escolhido e o processo repete-se.

Qual o custo associado a cada movimento?

O custo associado a cada movimento define-se path cost. É a distância que a múmia percorre desde o estado inicial até ao 1º cérebro que encontra, e depois esse valor volta a zero, voltando-se a calcular até a múmia chegar ao próximo cérebro.

Que tipo de Heurísticas são aplicáveis?

As Heurísticas aplicáveis devem ser admissíveis, ou seja, nunca a distância em linha reta pode ser estritamente superior à distância real, desta forma garantimos que a heurística irá encontrar a solução.

## **IMPLEMENTAÇÃO**

### **Algoritmos de pesquisa cega**

Nos algoritmos de procura cega, não existe nenhuma informação sobre o problema para ajudar no processo de geração e teste de nós. Definimos um modo sistemático de navegar na árvore de procura, até que chegue ao estado final, podendo ser analisado de duas maneiras: analisar repetidamente um sucessor do último nó analisado; ou analisar todos os sucessores de um dado nó, antes de passar para a análise de todos os sucessores dos sucessores.

### **Algoritmos de pesquisa heurísticas**

Nos algoritmos de procura heurística, admitimos que possuímos informação adicional que nos torna capaz de estimar o custo do caminho do nó corrente até ao nó solução, dado pela função  $h(n)$ . Pretendendo-se assim que a solução seja melhor, no caso da procura sôfrega, e que a melhor solução seja encontrada pelo  $A^*$ , que tenta escolher a cada instante o melhor caminho passando pelo nó  $n$ , utilizando a função  $f(n) = g(n) + h(n)$ .

### **Heurísticas**

Utilizamos a distância euclidiana e a distância de Manhattan.

### **Algoritmos estocásticos:**

A recristalização simulada não obteve sucesso em nenhum dos mapas....

## EXPERIMENTAÇÃO

### PROCURA CEGA:

List size limit: 200 000

Max Number of expansion: 300 000

### PROCURA HEURISTICA

List size limit: 100 000

Max Number of expansion: 200 000

### PROCURA ESTOCASTICA

List size limit: 100 000

Max Number of expansion: 200 000

### MAPA jumbomap

	Sucesso/ Fracasso	Discriminação	Tempo	Memória	PATH COST
Em largura primeiro	NÃO	NÃO	16778	ERRO	
Em profundidade primeiro	SIM	NAO	832	731	5293-5007-3749
Profundidade limitada LIMITE 1000	SIM	NAO	832	731	4450-344-3749
Custo Uniforme	NAO	NAO	66916	ERRO	
Aprofundamento Progressivo LIMITE 1000	SIM	NAO			
Sôfrega - Euclidiana	SIM	NAO	39	228	212-268-160
Sôfrega – Manhattan	SIM	NAO	32	145	162-72-110
A* - Euclidiana	SIM	SIM	3688	2648	140-50-101
A* - Manhattan	SIM	SIM	3501	2158	140-50-101
Procura Aleatória	NAO	NAO	252457	ERRO	
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 100					
Recristalização simulada – Euclidiana Temperatura = 60 Tdecrementa = 30					
Recristalização simulada – Manhattan					

Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 100					
Recristalização simulada – Manhattan Temperatura = 60 Tdecrementa = 30					

### Labyrinth

	Sucesso/ Fracasso	Discriminação	Tempo	Memória	PATH COST
Em largura primeiro	NAO	NAO	99547	ERRO	
Em profundidade primeiro	SIM	NAO	29	16	592-476-69
Profundidade limitada LIMITE 400	SIM	NAO	29	16	592-476-69
Custo Uniforme	NAO	NAO	104112 4	ERRO	
Aprofundamento Progressivo LIMITE 20	SIM	NAO	29	16	130-78-69
Sôfrega - Euclidiana	SIM	NAO	21	92	58-45-63
Sôfrega – Manhattan	SIM	NAO	24	78	57-72-56
A* - Euclidiana	SIM	SIM	849	425	56-47-53
A* - Manhattan	SIM	SIM	705	367	56-47-53
Procura Aleatória	NAO	NAO	34769	ERRO	
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 100					
Recristalização simulada – Euclidiana Temperatura = 60 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300					

Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 100					
Recristalização simulada – Manhattan Temperatura = 60 Tdecrementa = 30					

### MediumMap

	Sucesso/ Fracasso	Discriminação	Tempo	Memória	PATH COST
Em largura primeiro	Só encontra o 1º cerebro	NAO	85166	ERRO	
Em profundidade primeiro	SIM	NAO	44	34	104-51-79
Profundidade limitada LIMITE 50	SIM	NAO	44	34	104-51-79
Custo Uniforme	NÃO			ERRO	
Aprofundamento Progressivo	SIM	NAO	44	34	104 – 51 -79
Sôfrega - Euclidiana	SIM	NAO	13	62	18-24-33
Sôfrega – Manhattan	SIM	NAO	15	65	18-20-30
A* - Euclidiana	SIM	SIM	39	87	18-19-13
A* - Manhattan	SIM	SIM	29	66	18-16-13
Procura Aleatória	SÓ encontra o 1ºcebrer o	nao	30183	erro	43
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 100					

Recristalização simulada – Euclidiana Temperatura = 60 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 100					
Recristalização simulada – Manhattan Temperatura = 60 Tdecrementa = 30					

#### Small

	Sucesso/ Fracasso	Discriminação	Tempo	Memória	PATH COST
Em largura primeiro	SIM	NAO	108	215	24 – 12 - 8
Em profundidade primeiro	SIM	NAO	5	7	60 – 76 - 8
Profundidade limitada Limite máximo: 500	SIM	NAO	5	7	60 – 76 - 8
Custo Uniforme	NAO	NAO	86994	200001	
Aprofundamento Progressivo LIMITE 20	SIM	SIM	5	7	48 – 27 – 8
Sôfrega - Euclidiana	SIM	NAO	7	50	28 – 12 -8
Sôfrega – Manhattan	SIM	NAO	6	34	24 – 12 -8
A* - Euclidiana	SIM	SIM	13	71	19 – 11 - 8
A* - Manhattan	SIM	SIM	12	52	19-11-8
Procura Aleatória SEED 30	SIM	NAO	160	482	25 – 11 -12
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Euclidiana Temperatura = 300					

Tdecrementa = 100					
Recristalização simulada – Euclidiana Temperatura = 60 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 100					
Recristalização simulada – Manhattan Temperatura = 60 Tdecrementa = 30					

#### SmallLabyrinth

	Sucesso/ Fracasso	Discriminação	Tempo	Memória	PATH COST
Em largura primeiro	nao	nao		ERRO	
Em profundidade primeiro	SIM	NAO	246	114	516 - 731
Profundidade limitada LIMITE 100	SIM	NAO	115	79	516 - 507
Custo Uniforme	NAO			ERRO	
Aprofundamento Progressivo LIMITE 40	SIM	NAO	4370	55	221 - 324
Sôfrega - Euclidiana	SIM	NAO	38	81	95 - 77
Sôfrega – Manhattan	SIM	NÃO	38	82	101 - 77
A* - Euclidiana	SIM	SIM	267	223	82-83
A* - Manhattan	SIM	SIM	240	231	82 - 78
Procura Aleatória	NAO	NÃO		ERRO	
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 30	NAO				
Recristalização simulada – Euclidiana Temperatura = 300	NAO				



Tdecrementa = 100					
Recristalização simulada – Euclidiana Temperatura = 60 Tdecrementa = 30	NAO				
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 30	NAO				
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 100	NAO				
Recristalização simulada – Manhattan Temperatura = 60 Tdecrementa = 30	NAO				

#### twoRocksOneBrain

	Sucesso/ Fracasso	Discriminação	Tempo	Memória	PATH COST
Em largura primeiro	SIM	NÃO	7256	17388	65
Em profundidade primeiro	SIM	NÃO	52	40	241
Profundidade limitada LIMITE 50	SIM	NÃO	52	40	241
Custo Uniforme	SIM	SIM	24535	53088	26
Aprofundamento Progressivo LIMITE 50	SIM	NÃO	52	40	241
Sôfrega - Euclidiana	SIM	NÃO	9	14	65
Sôfrega – Manhattan	SIM	NÃO	9	14	65
A* - Euclidiana	SIM	SIM	55	23	26
A* - Manhattan	SIM	SIM	52	28	26
Procura Aleatória	NAO	NAO		ERRO	
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 30	NAO				
Recristalização simulada – Euclidiana Temperatura = 300	NAO				

Tdecrementa = 100					
Recristalização simulada – Euclidiana Temperatura = 60 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 100					
Recristalização simulada – Manhattan Temperatura = 60 Tdecrementa = 30					

#### Urock

	Sucesso/ Fracasso	Discriminação	Tempo	Memória	PATH COST
Em largura primeiro	NAO	NAO		ERRO	
Em profundidade primeiro	SIM	NAO	25	17	61
Profundidade limitada LIMITE 50	SIM	NAO	25	17	61
Custo Uniforme	NAO			ERRO	
Aprofundamento Progressivo LIMITE 40	SIM	NAO	25	17	61
Sôfrega - Euclidiana	SIM	NAO	207	65	35
Sôfrega – Manhattan	SIM	NAO	247	135	35
A* - Euclidiana	SIM	SIM	309	62	34
A* - Manhattan	SIM	SIM	356	90	34
Procura Aleatória	NAO			ERRO	
Recristalização simulada – Euclidiana Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Euclidiana Temperatura = 300					

Tdecrementa = 100					
Recristalização simulada – Euclidiana Temperatura = 60 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 30					
Recristalização simulada – Manhattan Temperatura = 300 Tdecrementa = 100					
Recristalização simulada – Manhattan Temperatura = 60 Tdecrementa = 30					

## BIBLIOGRAFIA

<https://docs.unity3d.com/ScriptReference/Random-value.html>

[https://en.wikipedia.org/wiki/Admissible\\_heuristic](https://en.wikipedia.org/wiki/Admissible_heuristic)

<https://fenix.tecnico.ulisboa.pt/downloadFile/3779572005298/cap4-proc-informada.pdf>

<https://math.stackexchange.com/questions/139600/how-to-calculate-the-euclidean-and-manhattan-distance>

<http://theory.stanford.edu/~amitp/GameProgramming/Heuristics.html>

Inteligência Artificial, Costa, Ernesto; Simões, Anabela, FCA